
Statistique descriptive bivariable et Pandas

Exercice 1 On considère les données disponibles sur moodle

`Data1_TP3.txt`

Ces données, issues du site Our World In Data, se présentent sous la forme

(nombre quotidien moyen de patients hospitalisés en soins critiques pour COVID 19, nombre quotidien moyen de décès dus au COVID 19, pays)

pour l'année 2021 pour l'ensemble des pays pour lesquels ces informations sont disponibles.

1. Pour chacune des deux séries statistiques marginales, calculer les indicateurs statistiques suivants : médiane, moyenne, variance et écart-type.
2. Tracer le diagramme de dispersion associé à la série statistique double. On pourra utiliser la fonction `scatter` de la bibliothèque `matplotlib.pyplot`.
3. Calculer la covariance et le coefficient de corrélation des deux séries statistiques marginales. On pourra utiliser les fonctions `cov` et `corrcoef` de la bibliothèque `numpy`.
4. En utilisant les formules vues en cours, calculer l'équation de la droite de régression linéaire
5. Vérifier le calcul précédent à l'aide de la fonction `polyfit` de la bibliothèque `numpy`.
6. Tracer la droite de régression linéaire sur le nuage de points précédemment obtenu.

Dans la deuxième partie de ce TP nous allons apprendre à utiliser la bibliothèque **Pandas**. Cette bibliothèque permet de lire (et écrire) des bases de données de différents formats et de faire des statistiques et de la visualisation de données à partir de la base de données.

Exercice 2 Pour cet exercice on va utiliser la base des données quotidiennes (du 24 Janvier 2020 au 8 Janvier 2022) du COVID en France issue du site Our World In Data et disponible à l'adresse

`Data2TP3.csv`

Cette base contient plus d'une soixantaine de données quotidiennes différentes sur plus de 700 jours. Les indicateurs utilisés dans cet exercice sont les suivants

- `date` : la date au format 'aaaa-mm-jj' ;
- `new_cases` : le nombre de nouveaux cas détectés ce jour ;
- `new_cases_smoothed` : le nombre de nouveaux cas moyenné sur les 7 derniers jours ;
- `hosp_patients` : le nombre de patients hospitalisés en raison du COVID ce jour ;
- `icu_patients` : le nombre de patients hospitalisés en soins critiques en raison du COVID ce jour ;
- `people_fully_vaccinated` : le nombre total de personnes vaccinés à ce jour.

Si l'on souhaite étudier d'autres indicateurs, le descriptif de tous les indicateurs est disponible à l'adresse

<https://github.com/owid/covid-19-data/blob/master/public/data/README.md>

1. Télécharger la base de données et la placer dans un répertoire bien identifié. En utilisant la fonction `read_csv`, charger la base de données. On veillera à bien indiquer le chemin d'accès de la base de données (soit lors de l'appel de la fonction `read_csv` soit directement dans l'éditeur). En **Python**, cette base de données est un objet de format **DataFrame**.
2. Extraire la colonne correspondant à l'indicateur `new_cases`. Afficher seulement les 8 premiers éléments.
3. Créer un nouveau **DataFrame** contenant toutes les informations du 1^{er} Février 2021. On pourra utiliser la méthode `loc`. Afficher le nombre de nouveaux cas détectés ce jour.

4. Calculer le nombre moyen de patients hospitalisés. On pourra utiliser la méthode `mean`.
Afficher les différents indicateurs statistiques du nombre de patients hospitalisés : minimum, maximum, moyenne, écart-type, médiane, quartiles. On pourra utiliser la méthode `describe`.
5. Afficher les mêmes indicateurs statistiques mais seulement pour les données de l'année 2021.
6. Tracer le diagramme en boîte correspondant à la question précédente.
7. Tracer la courbe du nombre de nouveaux cas (moyennés sur 7 jours) en fonction du temps. On pourra utiliser la méthode `plot` en spécifiant les arguments `x` et `y`.
8. Tracer sur un même graphique les courbes du nombre de nouveaux cas (moyenné sur 7 jours), du nombre de patients hospitalisés et du nombre de patients hospitalisés en soins critiques en fonction du temps. On pourra procéder comme précédemment en donnant pour le paramètre `y` non plus un seul indicateur mais la liste des indicateurs à tracer.
Améliorer la visualisation en restreignant les données tracées aux dates antérieures au 30 Novembre 2021 et en traçant le nombre de patients hospitalisés en soins critiques avec sa propre échelle (grâce au paramètre `secondary_y` de la méthode `plot`).
9. Tracer sur un même graphique les diagrammes en bandes du nombre de nouveaux cas (moyenné sur 7 jours) et du nombre de patients hospitalisés sur la période du 1^{er} Novembre 2021 au 15 Décembre 2021. On pourra utiliser la méthode `plot.bar`.
10. Tracer dans la même fenêtre, les diagrammes en bandes du nombre de nouveaux cas (moyenné sur 7 jours), du nombre de patients hospitalisés et du nombre de patients hospitalisés en soins critiques sur la période du 1^{er} Novembre 2021 au 15 Décembre 2021. On pourra utiliser le paramètre `subplots`.
11. *Question facultative.* Tracer dans la même fenêtre les 3 graphiques suivants : le diagramme en bandes de la question précédente, le même mais sur la période du 15 Septembre 2020 au 31 Octobre 2020 et le tracé du nombre de personnes vaccinés en fonction du temps (avec la méthode `plot`). On pourra utiliser la fonction `subplots` de la bibliothèque `matplotlib.pyplot` et spécifier le paramètre `ax` lors de chaque tracé.